Компьютерная графика

Лекция 15: оптимизация рендеринга, timer queries, batching, instancing, uniform buffers, frustum culling, occlusion culling

2021

Оптимизация – это сложно

На производительность (CPU) влияют:

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling
- Количество и паттерн доступов к памяти (cache-friendliness)

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling
- Количество и паттерн доступов к памяти (cache-friendliness)
- Помещаются ли данные в кэш

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling
- Количество и паттерн доступов к памяти (cache-friendliness)
- Помещаются ли данные в кэш
- Branch prediction

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling
- Количество и паттерн доступов к памяти (cache-friendliness)
- Помещаются ли данные в кэш
- Branch prediction
- Как функции программы лежат в памяти (опять кэш)

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling
- Количество и паттерн доступов к памяти (cache-friendliness)
- Помещаются ли данные в кэш
- Branch prediction
- Как функции программы лежат в памяти (опять кэш)
- Оптимизации компилятора

Оптимизация – это сложно

На производительность (CPU) влияют:

- Общая загруженность системы
- Throttling
- Количество и паттерн доступов к памяти (cache-friendliness)
- Помещаются ли данные в кэш
- Branch prediction
- Как функции программы лежат в памяти (опять кэш)
- Оптимизации компилятора
- Многое другое

Оптимизация на GPU – это очень сложно

- Асинхронность

Оптимизация на GPU – это очень сложно

- Асинхронность
- Параллельность

Оптимизация на GPU – это очень сложно

- Асинхронность
- Параллельность
- Много встроенных операций (fixed-function pipeline)

Оптимизация на GPU – это очень сложно

- Асинхронность
- Параллельность
- Много встроенных операций (fixed-function pipeline)
- Сложные операции с памятью (доступ к текстуре: mipmaps + фильтрация)

Оптимизация на GPU – это очень сложно

- Асинхронность
- Параллельность
- Много встроенных операций (fixed-function pipeline)
- Сложные операции с памятью (доступ к текстуре: mipmaps + фильтрация)
- Многое другое

Измерение времени работы – неправильный способ

```
while (true) {
  auto frame_start = clock::now();

  // нарисовали сцену
  ...

  auto frame_end = clock::now();

  SwapBuffers();
}
```

Измерение времени работы – неправильный способ

```
while (true) {
  auto frame_start = clock::now();

  // нарисовали сцену
  ...

  auto frame_end = clock::now();

  SwapBuffers();
}
```

- `frame_end - frame_start` – сколько времени ушло на то, чтобы **вызвать OpenGL-команды**

Измерение времени работы – неправильный способ

```
while (true) {
  auto frame_start = clock::now();

  // нарисовали сцену
  ...

  auto frame_end = clock::now();

  SwapBuffers();
}
```

- `frame_end - frame_start` – сколько времени ушло на то, чтобы **вызвать OpenGL-команды**
- В реальности драйвер поставил их в очередь, и скорее всего GPU ещё не начала их выполнять

Измерение времени работы – простой способ

```
disableVsync();
auto last_frame_start = clock::now();
while (true) {
  auto frame_start = clock::now();
  auto frame_time = frame_start - last_frame_start;
  last_frame_start = frame_start;

  // нарисовали сцену
  ...

  SwapBuffers();
}
```

Измерение времени работы – простой способ

```
disableVsync();
auto last_frame_start = clock::now();
while (true) {
  auto frame_start = clock::now();
  auto frame_time = frame_start - last_frame_start;
  last_frame_start = frame_start;

  // нарисовали сцену
  ...

  SwapBuffers();
}
```

- Из-за выключенного vsync видеокарта будет работать $\pm$ постоянно

Измерение времени работы – простой способ

```
disableVsync();
auto last_frame_start = clock::now();
while (true) {
  auto frame_start = clock::now();
  auto frame_time = frame_start - last_frame_start;
  last_frame_start = frame_start;

  // нарисовали сцену
  ...

  SwapBuffers();
}
```

- Из-за выключенного vsync видеокарта будет работать $\pm$ постоянно
- В итоге мы получим примерное время, тратящееся на рисование одного кадра

Измерение времени работы: glFlush и glFinish

- Многие (старые) туториалы по измерению времени кадра советуют вызывать `glFlush` или `glFinish` в конце кадра

Измерение времени работы: glFlush и glFinish

- Многие (старые) туториалы по измерению времени кадра советуют вызывать `glFlush` или `glFinish` в конце кадра
- `glFlush` сбрасывает буфер команд (хранящийся внутри драйвера) с CPU на GPU

Измерение времени работы: glFlush и glFinish

- Многие (старые) туториалы по измерению времени кадра советуют вызывать `glFlush` или `glFinish` в конце кадра
- `glFlush` сбрасывает буфер команд (хранящийся внутри драйвера) с CPU на GPU
- `glFinish` ждёт, пока GPU не завершит обрабатывать все посланные команды

Измерение времени работы: glFlush и glFinish

- Многие (старые) туториалы по измерению времени кадра советуют вызывать `glFlush` или `glFinish` в конце кадра
- `glFlush` сбрасывает буфер команд (хранящийся внутри драйвера) с CPU на GPU
- `glFinish` ждёт, пока GPU не завершит обрабатывать все посланные команды
- `SwapBuffers` сама вызывает `glFlush`

Измерение времени работы: glFlush и glFinish

- Многие (старые) туториалы по измерению времени кадра советуют вызывать `glFlush` или `glFinish` в конце кадра
- `glFlush` сбрасывает буфер команд (хранящийся внутри драйвера) с CPU на GPU
- `glFinish` ждёт, пока GPU не завершит обрабатывать все посланные команды
- `SwapBuffers` сама вызывает `glFlush`
- `glFinish` ухудшает производительность: половину времени вы отправляете команды на GPU, а GPU (скорее всего) ничего не делает; половину времени вы ждёте, пока GPU закончит выполнять команды

Измерение времени работы: FPS vs frame duration

- FPS (frames per second, количество кадров в секунду) – очень неудобная метрика:

Измерение времени работы: FPS vs frame duration

- FPS (frames per second, количество кадров в секунду) – очень неудобная метрика:
  - Нелинейна: если кадр рисовался 10 мс, и мы добавили что-то рисующееся 1 мс, и ещё что-то рисующееся 1 мс, то FPS изменялся от 100 до 90.9 до 83.3

Измерение времени работы: FPS vs frame duration

- FPS (frames per second, количество кадров в секунду) – очень неудобная метрика:
  - Нелинейна: если кадр рисовался 10 мс, и мы добавили что-то рисующееся 1 мс, и ещё что-то рисующееся 1 мс, то FPS изменялся от 100 до 90.9 до 83.3
- Обычно используют время, тратящееся на рисование кадра или конкретного объекта/эффекта (миллисекунды/микросекунды)

Измерение времени работы – правильный способ: timer queries

- Query objects – объекты OpenGL, позволяющие узнать некоторую статистику с GPU:

Измерение времени работы – правильный способ: timer queries

- Query objects – объекты OpenGL, позволяющие узнать некоторую статистику с GPU:
  - Сколько было нарисовано пикселей

Измерение времени работы – правильный способ: timer queries

- Query objects – объекты OpenGL, позволяющие узнать некоторую статистику с GPU:
  - Сколько было нарисовано пикселей
  - Сколько сгенерировано примитивов (геометрическим шейдером)

Измерение времени работы – правильный способ: timer queries

- Query objects – объекты OpenGL, позволяющие узнать некоторую статистику с GPU:
  - Сколько было нарисовано пикселей
  - Сколько сгенерировано примитивов (геометрическим шейдером)
  - Сколько прошло времени

Измерение времени работы – правильный способ: timer queries

- Query objects – объекты OpenGL, позволяющие узнать некоторую статистику с GPU:
  - Сколько было нарисовано пикселей
  - Сколько сгенерировано примитивов (геометрическим шейдером)
  - Сколько прошло времени
- `glGenQueries/glDeleteQueries`

Измерение времени работы – правильный способ: timer queries

- Query objects – объекты OpenGL, позволяющие узнать некоторую статистику с GPU:
  - Сколько было нарисовано пикселей
  - Сколько сгенерировано примитивов (геометрическим шейдером)
  - Сколько прошло времени
- `glGenQueries/glDeleteQueries`
- **Нет** `glBindQuery`!

Измерение времени работы – правильный способ: timer queries

- `glBeginQuery/glEndQuery` – статистика будет собрана для команд между этими вызовами

Измерение времени работы – правильный способ: timer queries

- `glBeginQuery/glEndQuery` – статистика будет собрана для команд между этими вызовами
- **Не могут** быть вложенными

Измерение времени работы – правильный способ: timer queries

- `glBeginQuery/glEndQuery` – статистика будет собрана для команд между этими вызовами
- **Не могут** быть вложенными

```
GLuint query_id;
glGenQueries(1, &query_id);

...

glBegin(GL_TIME_ELAPSED, query_id);

// что-нибудь рисуем

glEnd(GL_TIME_ELAPSED);
```

Измерение времени работы – правильный способ: timer queries

- GPU работает асинхронно $\Rightarrow$ результат query будет готов не сразу

Измерение времени работы – правильный способ: timer queries

- GPU работает асинхронно $\Rightarrow$ результат query будет готов не сразу
- Узнать, готов ли результат:

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT_AVAILABLE, &result);
```

Измерение времени работы – правильный способ: timer queries

- GPU работает асинхронно $\Rightarrow$ результат query будет готов не сразу
- Узнать, готов ли результат:

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT_AVAILABLE, &result);
```

- Получить результат (блокирует поток, если результат ещё не готов; неявно вызывает `glFlush`)

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT, &result);
```

Измерение времени работы – правильный способ: timer queries

- GPU работает асинхронно $\Rightarrow$ результат query будет готов не сразу
- Узнать, готов ли результат:

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT_AVAILABLE, &result);
```

- Получить результат (блокирует поток, если результат ещё не готов; неявно вызывает `glFlush`)

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT, &result);
```

- Время возвращается в **наносекундах**, т.е. знаковый 32-битный тип может представить 2 секунды

Измерение времени работы – правильный способ: timer queries

- GPU работает асинхронно $\Rightarrow$ результат query будет готов не сразу
- Узнать, готов ли результат:

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT_AVAILABLE, &result);
```

- Получить результат (блокирует поток, если результат ещё не готов; неявно вызывает `glFlush`)

```
glGetQueryObjectiv(query_id,
  GL_QUERY_RESULT, &result);
```

- Время возвращается в **наносекундах**, т.е. знаковый 32-битный тип может представить 2 секунды
- Если 64-битные и беззнаковые версии этих функций

Измерение времени работы – правильный способ: пул timer queries

- Хотим мерять время рисования каждого кадра, но результат для предыдущего кадра может быть не готов к началу следующего кадра

Измерение времени работы – правильный способ: пул timer queries

- Хотим мерять время рисования каждого кадра, но результат для предыдущего кадра может быть не готов к началу следующего кадра
- $\Rightarrow$ Заводим пул (pool) query-объектов:

Измерение времени работы – правильный способ: пул timer queries

- Хотим мерять время рисования каждого кадра, но результат для предыдущего кадра может быть не готов к началу следующего кадра
- $\Rightarrow$ Заводим пул (pool) query-объектов:
  - Храним расширяемый массив (`std::vector`) query-объектов: ID + свободен или нет

Измерение времени работы – правильный способ: пул timer queries

- Хотим мерять время рисования каждого кадра, но результат для предыдущего кадра может быть не готов к началу следующего кадра
- $\Rightarrow$ Заводим пул (pool) query-объектов:
  - Храним расширяемый массив (`std::vector`) query-объектов: ID + свободен или нет
  - Когда нам нужен новый query, ищем в массиве свободный объект, если такого нет - добавляем новый

Измерение времени работы – правильный способ: пул timer queries

- Хотим мерять время рисования каждого кадра, но результат для предыдущего кадра может быть не готов к началу следующего кадра
- $\Rightarrow$ Заводим пул (pool) query-объектов:
  - Храним расширяемый массив (`std::vector`) query-объектов: ID + свободен или нет
  - Когда нам нужен новый query, ищем в массиве свободный объект, если такого нет - добавляем новый
  - В конце рисования кадра проходим по всем несвободным объектам и проверяем: если результат уже готов, обрабатываем его и помечаем объект свободным

Измерение времени работы – правильный способ: пул timer queries

- Хотим мерять время рисования каждого кадра, но результат для предыдущего кадра может быть не готов к началу следующего кадра
- $\Rightarrow$ Заводим пул (pool) query-объектов:
  - Храним расширяемый массив (`std::vector`) query-объектов: ID + свободен или нет
  - Когда нам нужен новый query, ищем в массиве свободный объект, если такого нет - добавляем новый
  - В конце рисования кадра проходим по всем несвободным объектам и проверяем: если результат уже готов, обрабатываем его и помечаем объект свободным
- Средний размер пула – на сколько кадров отстаёт GPU от CPU

Timer queries: ссылки

- khronos.org/opengl/wiki/Query_Object
- Туториал по использованию timer queries

Поиск bottleneck'а

- Мы знаем, что что-то тормозит

Поиск bottleneck'a

- Мы знаем, что что-то тормозит
- OpenGL pipeline включает много компонентов, какой именно тормозит?

Поиск bottleneck'a

- Мы знаем, что что-то тормозит
- OpenGL pipeline включает много компонентов, какой именно тормозит?
- Обычно компоненты конвейера влияют на следующие за ними компоненты

Поиск bottleneck'a

- Мы знаем, что что-то тормозит
- OpenGL pipeline включает много компонентов, какой именно тормозит?
- Обычно компоненты конвейера влияют на следующие за ними компоненты
  - Больше вершин $\Rightarrow$ больше вызовов вершинного шейдера
  - Больше примитивов $\Rightarrow$ больше пикселей
  - Больше пикселей $\Rightarrow$ больше вызовов фрагментного шейдера
  - Больше пикселей $\Rightarrow$ больше операций записи в память

Поиск bottleneck'а

- Мы знаем, что что-то тормозит
- OpenGL pipeline включает много компонентов, какой именно тормозит?
- Обычно компоненты конвейера влияют на следующие за ними компоненты
  - Больше вершин $\Rightarrow$ больше вызовов вершинного шейдера
  - Больше примитивов $\Rightarrow$ больше пикселей
  - Больше пикселей $\Rightarrow$ больше вызовов фрагментного шейдера
  - Больше пикселей $\Rightarrow$ больше операций записи в память
- Удобно искать bottleneck с конца конвейера

Поиск bottleneck'a

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)

Поиск bottleneck'a

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)

Поиск bottleneck'a

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим число вершин (параметр `count` в `glDraw*`)

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим число вершин (параметр `count` в `glDraw*`)
  - Стало лучше? $\Rightarrow$ Слишком много вершин

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим число вершин (параметр `count` в `glDraw*`)
  - Стало лучше? $\Rightarrow$ Слишком много вершин
- Ничего не помогло $\Rightarrow$ CPU-bound

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим число вершин (параметр `count` в `glDraw*`)
  - Стало лучше? $\Rightarrow$ Слишком много вершин
- Ничего не помогло $\Rightarrow$ CPU-bound
  - Слишком много OpenGL-вызовов

Поиск bottleneck'а

- Упростим до предела фрагментный шейдер (напр. выведем фиксированный цвет)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим размер окна до чего-нибудь в духе 50x50 пикселей
  - Стало лучше? $\Rightarrow$ Слишком много операций записи в память
- Упростим до предела вершинный шейдер (напр. вернём фиксированные координаты)
  - Стало лучше? $\Rightarrow$ Слишком тяжёлый фрагментный шейдер
- Уменьшим число вершин (параметр `count` в `glDraw*`)
  - Стало лучше? $\Rightarrow$ Слишком много вершин
- Ничего не помогло $\Rightarrow$ CPU-bound
  - Слишком много OpenGL-вызовов
  - Слишком много других операций на CPU

Оптимизация шейдеров

- Выполняем меньше операций

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)
- Реорганизуем вычисления (напр. `exp(a+b+c+d)` вместо `exp(a)*exp(b)*exp(c)*exp(d)`)

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)
- Реорганизуем вычисления (напр. `exp(a+b+c+d)` вместо `exp(a)*exp(b)*exp(c)*exp(d)`)
- Предпосчитываем что-нибудь (в константный массив в шейдере или в текстуру)

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)
- Реорганизуем вычисления (напр. `exp(a+b+c+d)` вместо `exp(a)*exp(b)*exp(c)*exp(d)`)
- Предпосчитываем что-нибудь (в константный массив в шейдере или в текстуру)
- Меньше читаем из текстур

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)
- Реорганизуем вычисления (напр. `exp(a+b+c+d)` вместо `exp(a)*exp(b)*exp(c)*exp(d)`)
- Предпосчитываем что-нибудь (в константный массив в шейдере или в текстуру)
- Меньше читаем из текстур
- Читаем из текстур меньшего размера (лучше утилизируется текстурный кэш)

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)
- Реорганизуем вычисления (напр. `exp(a+b+c+d)` вместо `exp(a)*exp(b)*exp(c)*exp(d)`)
- Предпосчитываем что-нибудь (в константный массив в шейдере или в текстуру)
- Меньше читаем из текстур
- Читаем из текстур меньшего размера (лучше утилизируется текстурный кэш)
- Близкие пиксели читают близкие части текстуры (лучше утилизируется текстурный кэш)

Оптимизация шейдеров

- Выполняем меньше операций
- Избегаем вызова сложных функций (`sin`, `exp`, `pow`)
- Реорганизуем вычисления (напр. `exp(a+b+c+d)` вместо `exp(a)*exp(b)*exp(c)*exp(d)`)
- Предпосчитываем что-нибудь (в константный массив в шейдере или в текстуру)
- Меньше читаем из текстур
- Читаем из текстур меньшего размера (лучше утилизируется текстурный кэш)
- Близкие пиксели читают близкие части текстуры (лучше утилизируется текстурный кэш)
- Используем mipmap'ы

Оптимизация числа вершин

- Используем индексированный рендеринг (меньше данных нужно прочитать из памяти; лучше используется вершинный кэш)

Оптимизация числа вершин

- Используем индексированный рендеринг (меньше данных нужно прочитать из памяти; лучше используется вершинный кэш)
- Используем примитивы, группирующие вершины – line strip, triangle strip, triangle fan, etc (те же причины)

Оптимизация числа вершин

- Используем индексированный рендеринг (меньше данных нужно прочитать из памяти; лучше используется вершинный кэш)
- Используем примитивы, группирующие вершины – line strip, triangle strip, triangle fan, etc (те же причины)
- Используем LOD (level of detail)

Оптимизация количества OpenGL-вызовов

- Batching: группируем объекты по используемому шейдеру, текстуре, другим настройкам (меньше переключения состояния OpenGL $\Rightarrow$ меньше OpenGL-вызовов)

Оптимизация количества OpenGL-вызовов

- Batching: группируем объекты по используемому шейдеру, текстуре, другим настройкам (меньше переключения состояния OpenGL $\Rightarrow$ меньше OpenGL-вызовов)
- Instancing: рисуем много объектов одним OpenGL-вызовом

Оптимизация количества OpenGL-вызовов

- Batching: группируем объекты по используемому шейдеру, текстуре, другим настройкам (меньше переключения состояния OpenGL $\Rightarrow$ меньше OpenGL-вызовов)
- Instancing: рисуем много объектов одним OpenGL-вызовом
- Uniform buffers: передаём uniform-переменные не по одной, а записываем их в буффер (вместо большого количества вызовов `glUniform*` один вызов `glBufferData`)

Оптимизация количества OpenGL-вызовов

- Batching: группируем объекты по используемому шейдеру, текстуре, другим настройкам (меньше переключения состояния OpenGL $\Rightarrow$ меньше OpenGL-вызовов)
- Instancing: рисуем много объектов одним OpenGL-вызовом
- Uniform buffers: передаём uniform-переменные не по одной, а записываем их в буффер (вместо большого количества вызовов `glUniform*` один вызов `glBufferData`)
- Indirect rendering: переносим вычисления того, что нужно нарисовать, на GPU (OpenGL 4.0 + compute shaders)

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру
  - Occlusion culling: не рисуем то, чего не видно (закрыто другими объектами)

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру
  - Occlusion culling: не рисуем то, чего не видно (закрыто другими объектами)
- Переводим рисование в отдельный поток
  - Освобождает основной (UI) поток

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру
  - Occlusion culling: не рисуем то, чего не видно (закрыто другими объектами)
- Переводим рисование в отдельный поток
  - Освобождает основной (UI) поток
  - Позволяет делать полезную работу, пока render-поток ждёт VSync

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру
  - Occlusion culling: не рисуем то, чего не видно (закрыто другими объектами)
- Переводим рисование в отдельный поток
  - Освобождает основной (UI) поток
  - Позволяет делать полезную работу, пока render-поток ждёт VSync
  - Сильно усложняет код

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру
  - Occlusion culling: не рисуем то, чего не видно (закрыто другими объектами)
- Переводим рисование в отдельный поток
  - Освобождает основной (UI) поток
  - Позволяет делать полезную работу, пока render-поток ждёт VSync
  - Сильно усложняет код
  - Все OpenGL-вызовы нужно делать из render-потока

Оптимизация чего угодно

- Рисуем поменьше
  - Frustum culling: не рисуем то, что не попадёт в камеру
  - Occlusion culling: не рисуем то, чего не видно (закрыто другими объектами)
- Переводим рисование в отдельный поток
  - Освобождает основной (UI) поток
  - Позволяет делать полезную работу, пока render-поток ждёт VSync
  - Сильно усложняет код
  - Все OpenGL-вызовы нужно делать из render-потока
  - Применяется только в крайних случаях

Оптимизация: ссылки

- khronos.org/opengl/wiki/Performance
- opengl.org/pipeline/article/vol003_8
- Доклад с GDC 2003, всё ещё актуальный

LOD (level of detail)

- Когда модель далеко от камеры, рисуем упрощённую модель вместо детализированной

LOD (level of detail)

- Когда модель далеко от камеры, рисуем упрощённую модель вместо детализированной
- Таких уровней детализации может быть несколько, вплоть до почти непрерывного изменения детализации (Unreal 5 Nanite)

LOD (level of detail)

- Когда модель далеко от камеры, рисуем упрощённую модель вместо детализированной
- Таких уровней детализации может быть несколько, вплоть до почти непрерывного изменения детализации (Unreal 5 Nanite)
- Упрощённая модель может иметь отдельные VAO/VBO/EBO, а может лежать вместе с основной моделью (рисование конкретного LOD'а сводится к передаче правильных `first` и `count` в `glDrawArrays` и т.п.)

LOD (level of detail)

- Когда модель далеко от камеры, рисуем упрощённую модель вместо детализированной
- Таких уровней детализации может быть несколько, вплоть до почти непрерывного изменения детализации (Unreal 5 Nanite)
- Упрощённая модель может иметь отдельные VAO/VBO/EBO, а может лежать вместе с основной моделью (рисование конкретного LOD'а сводится к передаче правильных `first` и `count` в `glDrawArrays` и т.п.)
- Автоматическая генерация упрощённой модели – предмет активных исследований
  - Большинство современных подходов используют edge collapse: пара вершин, соединённых ребром, схлопывается в одну вершину

LOD (level of detail)

- Когда модель далеко от камеры, рисуем упрощённую модель вместо детализированной
- Таких уровней детализации может быть несколько, вплоть до почти непрерывного изменения детализации (Unreal 5 Nanite)
- Упрощённая модель может иметь отдельные VAO/VBO/EBO, а может лежать вместе с основной моделью (рисование конкретного LOD'а сводится к передаче правильных `first` и `count` в `glDrawArrays` и т.п.)
- Автоматическая генерация упрощённой модели – предмет активных исследований
  - Большинство современных подходов используют edge collapse: пара вершин, соединённых ребром, схлопывается в одну вершину
- Конкретный уровень детализации выбирается на основе желаемого видимого размера треугольников

LOD (level of detail)

- Когда модель далеко от камеры, рисуем упрощённую модель вместо детализированной
- Таких уровней детализации может быть несколько, вплоть до почти непрерывного изменения детализации (Unreal 5 Nanite)
- Упрощённая модель может иметь отдельные VAO/VBO/EBO, а может лежать вместе с основной моделью (рисование конкретного LOD'а сводится к передаче правильных `first` и `count` в `glDrawArrays` и т.п.)
- Автоматическая генерация упрощённой модели – предмет активных исследований
  - Большинство современных подходов используют edge collapse: пара вершин, соединённых ребром, схлопывается в одну вершину
- Конкретный уровень детализации выбирается на основе желаемого видимого размера треугольников
- Выбор уровня детализации можно перенести на GPU (indirect rendering)

Batching

- Может быть неявным: объекты, использующие один шейдер/материал/etc сами по себе лежат в одном месте

Batching

- Может быть неявным: объекты, использующие один шейдер/материал/etc сами по себе лежат в одном месте
- Может быть явным: движок рендеринга получает список объектов и сам их сортирует

Instanced rendering (instancing)

- Позволяет рисовать несколько копий (instances) объекта одним OpenGL-вызовом

Instanced rendering (instancing)

- Позволяет рисовать несколько копий (instances) объекта одним OpenGL-вызовом
- Обычно атрибуты вершин берутся в соответствии с индексом вершины: `offset + stride * vertexID`

Instanced rendering (instancing)

- Позволяет рисовать несколько копий (instances) объекта одним OpenGL-вызовом
- Обычно атрибуты вершин берутся в соответствии с индексом вершины: `offset + stride * vertexID`
- При использовании instancing конкретный атрибут вычисляется из номера instance:
  `offset + stride * (instanceID / divisor)` (целочисленное деление)

Instanced rendering (instancing)

- Позволяет рисовать несколько копий (instances) объекта одним OpenGL-вызовом
- Обычно атрибуты вершин берутся в соответствии с индексом вершины: `offset + stride * vertexID`
- При использовании instancing конкретный атрибут вычисляется из номера instance:
  `offset + stride * (instanceID / divisor)` (целочисленное деление)
- Включить instancing для конкретного атрибута:
  `glVertexAttribDivisor(index, divisor)`:
  - `divisor = 0`: атрибут не использует instancing и использует номер вершины
  - `divisor != 0`: атрибут использует instancing и использует номер instance (по формуле выше)

Instanced rendering (instancing)

- Позволяет рисовать несколько копий (instances) объекта одним OpenGL-вызовом
- Обычно атрибуты вершин берутся в соответствии с индексом вершины: `offset + stride * vertexID`
- При использовании instancing конкретный атрибут вычисляется из номера instance:
  `offset + stride * (instanceID / divisor)` (целочисленное деление)
- Включить instancing для конкретного атрибута:
  `glVertexAttribDivisor(index, divisor)`:
  - `divisor = 0`: атрибут не использует instancing и использует номер вершины
  - `divisor != 0`: атрибут использует instancing и использует номер instance (по формуле выше)
- Вызвать instanced rendering: `glDrawArraysInstanced`
  - Параметры – те же, что у `glDrawArrays`, плюс последний параметр – количество instance'ов (значения `instanceID` будут в диапазоне `0 .. isntance_count-1`)

Instanced rendering (instancing)

- Позволяет рисовать несколько копий (instances) объекта одним OpenGL-вызовом
- Обычно атрибуты вершин берутся в соответствии с индексом вершины: `offset + stride * vertexID`
- При использовании instancing конкретный атрибут вычисляется из номера instance:
  `offset + stride * (instanceID / divisor)` (целочисленное деление)
- Включить instancing для конкретного атрибута:
  `glVertexAttribDivisor(index, divisor)`:
  - `divisor = 0`: атрибут не использует instancing и использует номер вершины
  - `divisor != 0`: атрибут использует instancing и использует номер instance (по формуле выше)
- Вызвать instanced rendering: `glDrawArraysInstanced`
  - Параметры – те же, что у `glDrawArrays`, плюс последний параметр – количество instance'ов (значения `instanceID` будут в диапазоне `0 .. isntance_count-1`)
- Аналогично есть `glDrawElementsInstanced`

Instancing: ссылки

- khronos.org/opengl/wiki/Vertex_Rendering#Instancing
- learnopengl.com/Advanced-OpenGL/Instancing
- ogldev.org/www/tutorial33/tutorial33.html
- habr.com/ru/post/352962

Uniform buffers

- Позволяет использовать в качестве uniform-переменных данные из буфера

Uniform buffers

- Позволяет использовать в качестве uniform-переменных данные из буфера
- Специальный тип (target) для буферов: `GL_UNIFORM_BUFFER` (создание и загрузка данных – так же, как для других буферов)

Uniform buffers

- Позволяет использовать в качестве uniform-переменных данные из буфера
- Специальный тип (target) для буферов: `GL_UNIFORM_BUFFER` (создание и загрузка данных – так же, как для других буферов)
- В шейдере – т.н. *buffer-backed interface block*

Uniform buffers

- Позволяет использовать в качестве uniform-переменных данные из буфера
- Специальный тип (target) для буферов: `GL_UNIFORM_BUFFER` (создание и загрузка данных – так же, как для других буферов)
- В шейдере – т.н. *buffer-backed interface block*
- Нужно быть внимательным с memory layout данных в буфере (конкретные правила описаны в спецификации)

Uniform buffers

- Позволяет использовать в качестве uniform-переменных данные из буфера
- Специальный тип (target) для буферов: `GL_UNIFORM_BUFFER` (создание и загрузка данных – так же, как для других буферов)
- В шейдере – т.н. *buffer-backed interface block*
- Нужно быть внимательным с memory layout данных в буфере (конкретные правила описаны в спецификации)
- Каждый interface block нужно привязать к *binding index*: `glGetUniformBlockIndex` + `glUniformBlockBinding` (в OpenGL 4.2 можно задать прямо в шейдере)
- Uniform buffer нужно привизать к тому же *binding index*: `glBindBufferBase` или `glBindBufferRange`

Uniform buffers: ссылки

- khronos.org/opengl/wiki/Uniform_Buffer_Object
- khronos.org/opengl/wiki/Interface_Block_(GLSL)#Buffer_backed
- learnopengl.com/Advanced-OpenGL/Advanced-GLSL

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)

Усечённая пирамида (frustum)

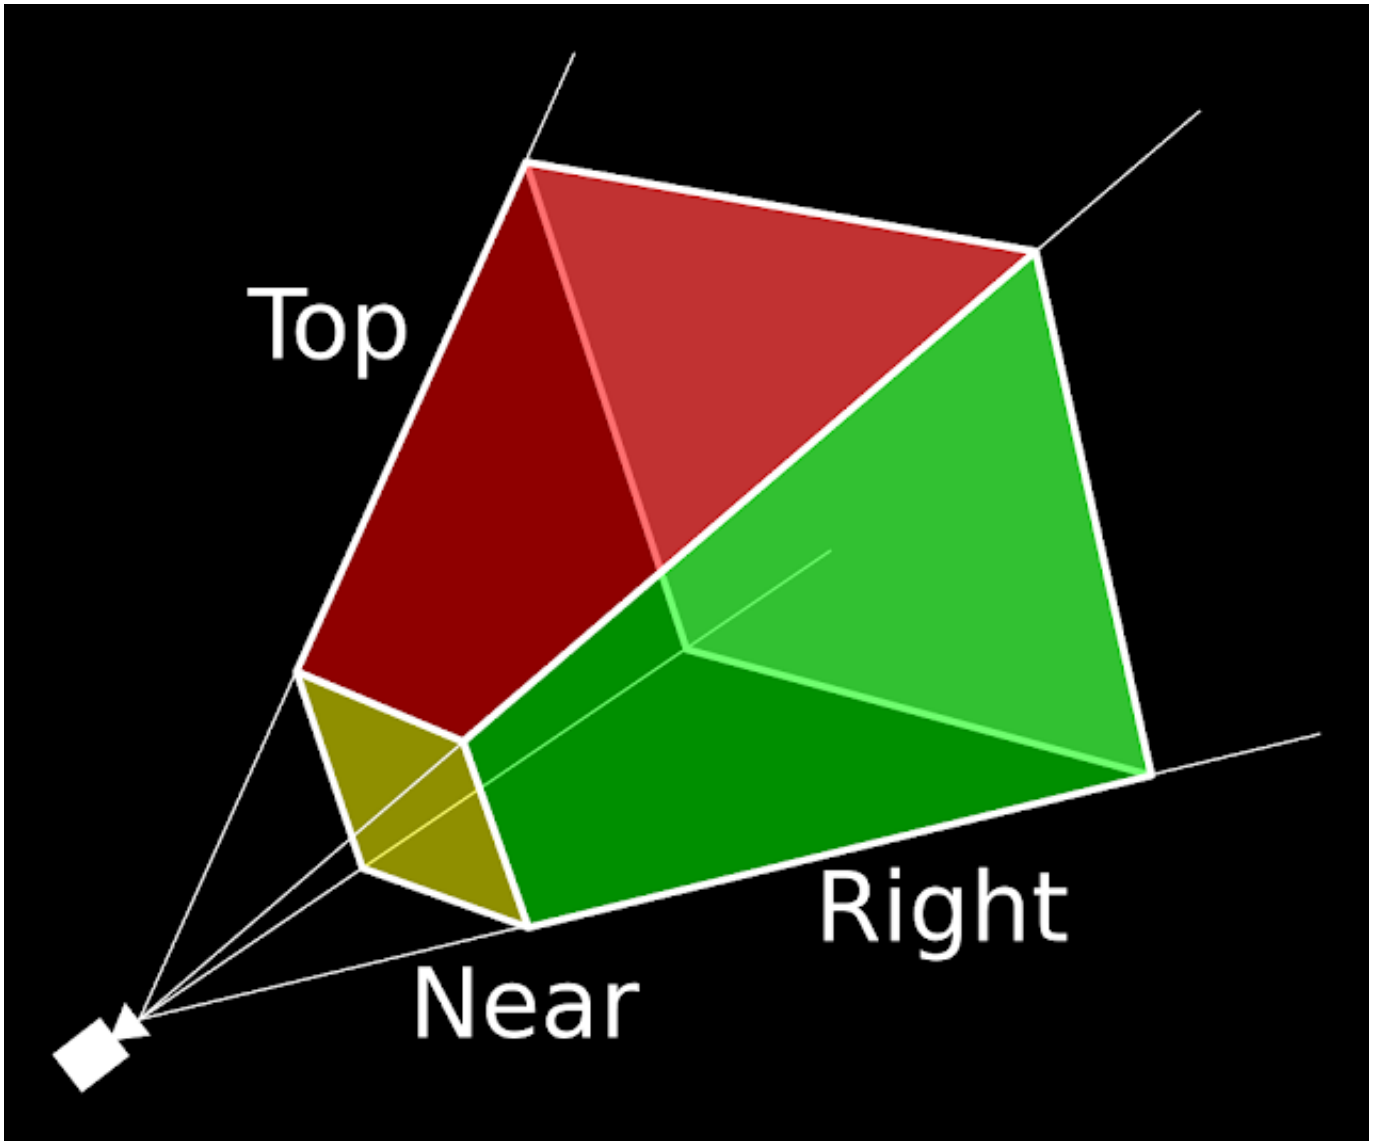

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления
  - Иметь поменьше вершин (упрощает поиск пересечений)

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления
  - Иметь поменьше вершин (упрощает поиск пересечений)
  - Быть выпуклой (упрощает поиск пересечений)

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления
  - Иметь поменьше вершин (упрощает поиск пересечений)
  - Быть выпуклой (упрощает поиск пересечений)
- Варианты оболочки:
  - Выпуклая оболочка – плотно прилегает, но дорого вычислять и много вершин

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления
  - Иметь поменьше вершин (упрощает поиск пересечений)
  - Быть выпуклой (упрощает поиск пересечений)
- Варианты оболочки:
  - Выпуклая оболочка – плотно прилегает, но дорого вычислять и много вершин
  - Ограничивающая сфера/эллипсоид – легко вычислять, довольно нетривиальный алгоритм пересечения

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления
  - Иметь поменьше вершин (упрощает поиск пересечений)
  - Быть выпуклой (упрощает поиск пересечений)
- Варианты оболочки:
  - Выпуклая оболочка – плотно прилегает, но дорого вычислять и много вершин
  - Ограничивающая сфера/эллипсоид – легко вычислять, довольно нетривиальный алгоритм пересечения
  - AABB (axis-aligned bounding box) – легко вычислять (но нужно пересчитывать каждый кадр), не всегда плотно прилегает, легко искать пересечения

Frustum culling

- Давайте не рисовать то, что заведомо не попадёт в камеру
- Видимая область камеры – параллелепипед (ортографическая проекция) или усечённая пирамида (перспективная проекция)
- Для каждого объекта нужно посчитать какую-нибудь оболочку (bounding volume) и пересечь её с видимой областью
- Оболочка должна:
  - Как можно плотнее прилегать к объекту
  - Быть дешёвой для вычисления
  - Иметь поменьше вершин (упрощает поиск пересечений)
  - Быть выпуклой (упрощает поиск пересечений)
- Варианты оболочки:
  - Выпуклая оболочка – плотно прилегает, но дорого вычислять и много вершин
  - Ограничивающая сфера/эллипсоид – легко вычислять, довольно нетривиальный алгоритм пересечения
  - AABB (axis-aligned bounding box) – легко вычислять (но нужно пересчитывать каждый кадр), не всегда плотно прилегает, легко искать пересечения
  - OBB (oriented bounding box) – легко вычислять (предподсчитали для модели, поворачиваем вместе с моделью), плотно прилегает, легко искать пересечения

Frustum culling: SAT

- Для детектирования пересечения выпуклых многогранников (frustum, AABB, OBB, etc.) обычно используется алгоритм, основанный на SAT – Separating Axis Theorem (в математике известна как HST – Hyperplane Separation Theorem)

Frustum culling: SAT

- Для детектирования пересечения выпуклых многогранников (frustum, AABB, OBB, etc.) обычно используется алгоритм, основанный на SAT – Separating Axis Theorem (в математике известна как HST – Hyperplane Separation Theorem)
- Пусть A и B – два непересекающихся замкнутых выпуклых подмножества Евклидова пространства (есть версия для Банаховых пространств). Тогда:

Frustum culling: SAT

- Для детектирования пересечения выпуклых многогранников (frustum, AABB, OBB, etc.) обычно используется алгоритм, основанный на SAT – Separating Axis Theorem (в математике известна как HST – Hyperplane Separation Theorem)
- Пусть A и B – два непересекающихся замкнутых выпуклых подмножества Евклидова пространства (есть версия для Банаховых пространств). Тогда:
  - HST: существует гиперплоскость (separating hyperplane), проходящая между этими подмножествами

Frustum culling: SAT

- Для детектирования пересечения выпуклых многогранников (frustum, AABB, OBB, etc.) обычно используется алгоритм, основанный на SAT – Separating Axis Theorem (в математике известна как HST – Hyperplane Separation Theorem)
- Пусть A и B – два непересекающихся замкнутых выпуклых подмножества Евклидова пространства (есть версия для Банаховых пространств). Тогда:
  - HST: существует гиперплоскость (separating hyperplane), проходящая между этими подмножествами
  - SAT: существует прямая (separating axis), такая, что проекции A и B на эту прямую не пересекаются

Frustum culling: SAT

- Для детектирования пересечения выпуклых многогранников (frustum, AABB, OBB, etc.) обычно используется алгоритм, основанный на SAT – Separating Axis Theorem (в математике известна как HST – Hyperplane Separation Theorem)
- Пусть A и B – два непересекающихся замкнутых выпуклых подмножества Евклидова пространства (есть версия для Банаховых пространств). Тогда:
  - HST: существует гиперплоскость (separating hyperplane), проходящая между этими подмножествами
  - SAT: существует прямая (separating axis), такая, что проекции A и B на эту прямую не пересекаются
  - HST $\Leftrightarrow$ SAT: гиперплоскость $\Leftrightarrow$ перпендикулярная ей прямая

Frustum culling: SAT

- Для детектирования пересечения выпуклых многогранников (frustum, AABB, OBB, etc.) обычно используется алгоритм, основанный на SAT – Separating Axis Theorem (в математике известна как HST – Hyperplane Separation Theorem)
- Пусть A и B – два непересекающихся замкнутых выпуклых подмножества Евклидова пространства (есть версия для Банаховых пространств). Тогда:
  - HST: существует гиперплоскость (separating hyperplane), проходящая между этими подмножествами
  - SAT: существует прямая (separating axis), такая, что проекции A и B на эту прямую не пересекаются
  - HST $\Leftrightarrow$ SAT: гиперплоскость $\Leftrightarrow$ перпендикулярная ей прямая
- N.B.: на этой же теореме основывается метод SVM – Support Vector Machine
- N.B.: тот же алгоритм используется для детектирования столкновений в физических движках

Frustum culling: SAT

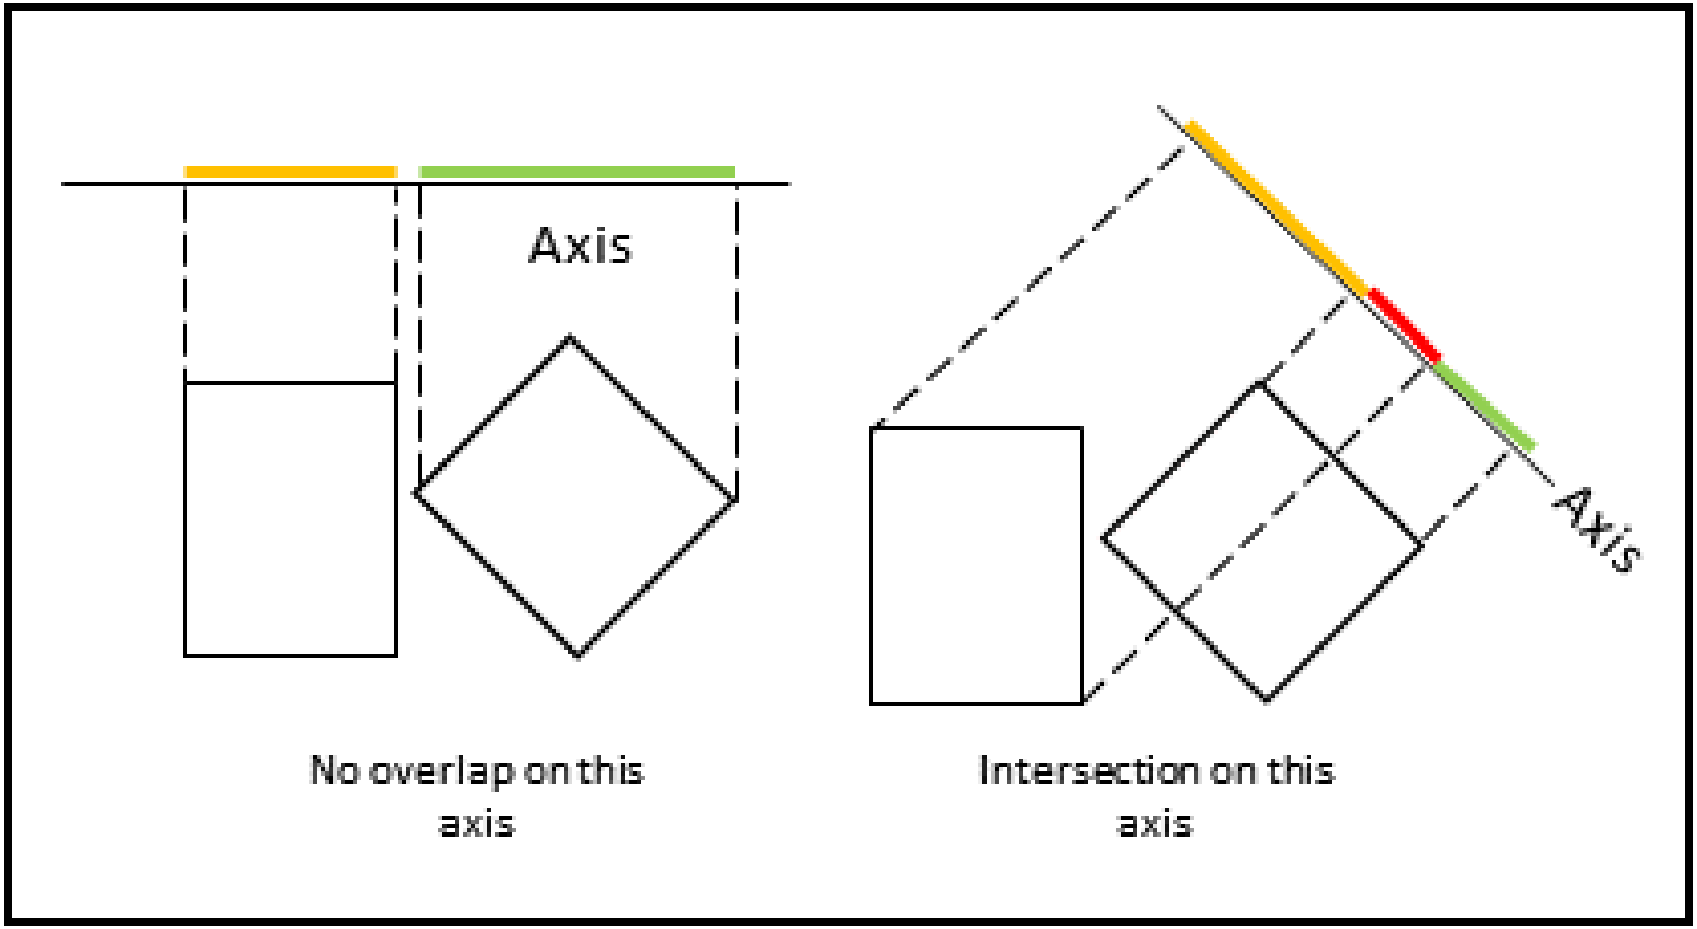

Frustum culling: вычисление проекции на прямую

- Проекция выпуклого замкнутого ограниченного множества на прямую – отрезок

Frustum culling: вычисление проекции на прямую

- Проекция выпуклого замкнутого ограниченного множества на прямую – отрезок
- Нужно выбрать некоторую точку o на прямой, тогда проекция точки p на прямую вычисляется как $(p - o) \cdot n$ (где n – вектор направления прямой)

Frustum culling: вычисление проекции на прямую

- Проекция выпуклого замкнутого ограниченного множества на прямую – отрезок
- Нужно выбрать некоторую точку o на прямой, тогда проекция точки p на прямую вычисляется как $(p - o) \cdot n$ (где n – вектор направления прямой)
- Выбор другой точки o или замена вектора n на коллинеарный приведёт к сдвигу и масштабированию проекций $\Rightarrow$ непересекающиеся проекции останутся непересекающимися

Frustum culling: вычисление проекции на прямую

- Проекция выпуклого замкнутого ограниченного множества на прямую – отрезок
- Нужно выбрать некоторую точку o на прямой, тогда проекция точки p на прямую вычисляется как $(p - o) \cdot n$ (где n – вектор направления прямой)
- Выбор другой точки o или замена вектора n на коллинеарный приведёт к сдвигу и масштабированию проекций $\Rightarrow$ непересекающиеся проекции останутся непересекающимися
- $\Rightarrow$ нам не важна начальная точка, можно вычислять $p \cdot n$ (интерпретируя точку p как радиус-вектор из начала координат)

Frustum culling: вычисление проекции на прямую

Псевдокод вычисления проекции выпуклого множества на прямую:

```
float vmin = inf, vmax = -inf;
for (p : vertices) {
  float v = dot(p, n);
  vmin = min(vmin, v);
  vmax = max(vmax, v);
}
```

Frustum culling: вычисление пересечения проекций

- Число принадлежит отрезку `[vmin, vmax]`, если $v_{min} \leq v \leq v_{max}$

Frustum culling: вычисление пересечения проекций

- Число принадлежит отрезку `[vmin, vmax]`, если $v_{min} \leq v \leq v_{max}$
- Число принадлежит пересечению двух отрезков, если выполняются два уравнения

$$\begin{cases} v^1_{min} \leq v \leq v^1_{max} \\ v^2_{min} \leq v \leq v^2_{max} \end{cases} \tag{1}$$

Frustum culling: вычисление пересечения проекций

- Число принадлежит отрезку `[vmin, vmax]`, если $v_{min} \leq v \leq v_{max}$
- Число принадлежит пересечению двух отрезков, если выполняются два уравнения

$$\begin{cases} v^1_{min} \leq v \leq v^1_{max} \\ v^2_{min} \leq v \leq v^2_{max} \end{cases} \tag{1}$$

- Чтобы эта система имела решения (т.е. отрезки пересекались), нужно

$$\begin{cases} v^1_{min} \leq v^2_{max} \\ v^2_{min} \leq v^1_{max} \end{cases} \tag{2}$$

Frustum culling: вычисление пересечения проекций

Псевдокод детектирования пересечения двух отрезков:

```
if (v1min <= v2max && v2min <= v1max)
  return true;
else
  return false;
```

Frustum culling: SAT

- Если проекции объектов на любые прямые пересекаются, то объекты пересекаются, иначе – не пересекаются

Frustum culling: SAT

- Если проекции объектов на любые прямые пересекаются, то объекты пересекаются, иначе – не пересекаются
- Возможных прямых бесконечно много, мы можем проверить только конечное их число

Frustum culling: SAT, 2D

- Будем мысленно сдвигать объекты вдоль separating axis друг к другу до первого пересечения

Frustum culling: SAT, 2D

- Будем мысленно сдвигать объекты вдоль separating axis друг к другу до первого пересечения
- Три варианта пересечения:
  - Ребро-ребро
  - Ребро-вершина
  - Вершина-вершина

Frustum culling: SAT, 2D

- Будем мысленно сдвигать объекты вдоль separating axis друг к другу до первого пересечения
- Три варианта пересечения:
  - Ребро-ребро
  - Ребро-вершина
  - Вершина-вершина
- Во всех трёх случаях в качестве направления separating axis можно взять нормаль к какому-нибудь ребру

Frustum culling: SAT, 2D

- Будем мысленно сдвигать объекты вдоль separating axis друг к другу до первого пересечения
- Три варианта пересечения:
  - Ребро-ребро
  - Ребро-вершина
  - Вершина-вершина
- Во всех трёх случаях в качестве направления separating axis можно взять нормаль к какому-нибудь ребру
- SAT для выпуклых многоугольников: в качестве множества направлений для separating axis берём множество нормалей к рёбрам обоих объектов

Frustum culling: SAT, 3D

- Можно рассмотреть ту же идею, но в 3D больше случаев

Frustum culling: SAT, 3D

- Можно рассмотреть ту же идею, но в 3D больше случаев
- SAT для выпуклых многогранников: в качестве множества направлений для separating axis берём
  - Множество нормалей к граням обоих объектов
  - $+$ множество попарных векторных произведений $e_1 \times e_2$, где e_1 и e_2 – рёбра первого и второго многогранников, соответственно (для всех пар рёбер)

Frustum culling: SAT, 3D

- Можно рассмотреть ту же идею, но в 3D больше случаев
- SAT для выпуклых многогранников: в качестве множества направлений для separating axis берём
  - Множество нормалей к граням обоих объектов
  - $+$ множество попарных векторных произведений $e_1 \times e_2$, где e_1 и e_2 – рёбра первого и второго многогранников, соответственно (для всех пар рёбер)
- N.B.: нас интересуют только направления с точностью до умножения на константу, так что во многих случаях необязательно рассматривать все грани и рёбра

Frustum culling: SAT, 3D

- Можно рассмотреть ту же идею, но в 3D больше случаев
- SAT для выпуклых многогранников: в качестве множества направлений для separating axis берём
  - Множество нормалей к граням обоих объектов
  - + множество попарных векторных произведений $e_1 \times e_2$, где e_1 и e_2 – рёбра первого и второго многогранников, соответственно (для всех пар рёбер)
- N.B.: нас интересуют только направления с точностью до умножения на константу, так что во многих случаях необязательно рассматривать все грани и рёбра
  - Например, у куба/параллелепипеда только три неколлинеарных нормали и три неколлинеарных ребра

Frustum culling: SAT, 3D

```
bool intersect_along(Body b1, Body b2, vec3 n) {
  auto p1 = project(b1.vertices, n);
  auto p2 = project(b2.vertices, n);
  return intersect(p1, p2);
}

bool intersect(Body b1, Body b2) {
  for (n : b1.face_normals) {
    if (intersect_along(b1, b2, n))
      return true;
  }

  for (n : b2.face_normals) {
    if (intersect_along(b1, b2, n))
      return true;
  }

  for (e1 : b1.edges) {
    for (e2 : b2.edges) {
      vec3 n = cross(e1, e2);
      if (intersect_along(b1, b2, n))
        return true;
    }
  }

  return false;
}
```

Frustum culling: вычисление camera frustum

- В независимости от проекции, комбинаторно видимая область – куб, т.е. имеет 8 вершин, 12 рёбер, и 6 граней, соединённых как в кубе

Frustum culling: вычисление camera frustum

- В независимости от проекции, комбинаторно видимая область – куб, т.е. имеет 8 вершин, 12 рёбер, и 6 граней, соединённых как в кубе
- Достаточно вычислить координаты 8-ми вершин

Frustum culling: вычисление camera frustum

- В независимости от проекции, комбинаторно видимая область – куб, т.е. имеет 8 вершин, 12 рёбер, и 6 граней, соединённых как в кубе
- Достаточно вычислить координаты 8-ми вершин
- Можно вычислить напрямую из параметров и свойств камеры $\Rightarrow$ сложный ad-hoc алгоритм

Frustum culling: вычисление camera frustum

- В независимости от проекции, комбинаторно видимая область – куб, т.е. имеет 8 вершин, 12 рёбер, и 6 граней, соединённых как в кубе
- Достаточно вычислить координаты 8-ми вершин
- Можно вычислить напрямую из параметров и свойств камеры $\Rightarrow$ сложный ad-hoc алгоритм
- Можно вычислить из матрицы T (view + projection):

Frustum culling: вычисление camera frustum

- В независимости от проекции, комбинаторно видимая область – куб, т.е. имеет 8 вершин, 12 рёбер, и 6 граней, соединённых как в кубе
- Достаточно вычислить координаты 8-ми вершин
- Можно вычислить напрямую из параметров и свойств камеры $\Rightarrow$ сложный ad-hoc алгоритм
- Можно вычислить из матрицы T (view + projection):
  - Координаты вершин видимой области в NDC (normalized device coordinates): $(\pm 1, \pm 1, \pm 1)$

Frustum culling: вычисление camera frustum

- В независимости от проекции, комбинаторно видимая область – куб, т.е. имеет 8 вершин, 12 рёбер, и 6 граней, соединённых как в кубе
- Достаточно вычислить координаты 8-ми вершин
- Можно вычислить напрямую из параметров и свойств камеры $\Rightarrow$ сложный ad-hoc алгоритм
- Можно вычислить из матрицы T (view + projection):
  - Координаты вершин видимой области в NDC (normalized device coordinates): $(\pm 1, \pm 1, \pm 1)$
  - Координаты вершин видимой области в сцене: $\text{Proj}\left(T^{-1} \cdot (\pm 1, \pm 1, \pm 1, 1)\right)$

Frustum culling

- Объекты можно как-то групировать, чтобы отсекать сразу большие группы объектов, не попадающие в камеру:

Frustum culling

- Объекты можно как-то групировать, чтобы отсекать сразу большие группы объектов, не попадающие в камеру:
  - Деревья (BVH – bounding volume hierarchy, octree, R-tree, ...)

Frustum culling

- Объекты можно как-то групировать, чтобы отсекать сразу большие группы объектов, не попадающие в камеру:
  - Деревья (BVH – bounding volume hierarchy, octree, R-tree, ...)
  - Сетки/bins: группируем объекты в ячейки квадратной/кубической сетки, отсекаем сразу целые ячейки

Frustum culling

- Объекты можно как-то групировать, чтобы отсекать сразу большие группы объектов, не попадающие в камеру:
  - Деревья (BVH – bounding volume hierarchy, octree, R-tree, ...)
  - Сетки/bins: группируем объекты в ячейки квадратной/кубической сетки, отсекаем сразу целые ячейки
- Можно перевести отсечение на GPU (indirect rendering)

Frustum culling: ссылки

- Есть много способов написать этот алгоритм; есть вариации, соптимизированные для параллелограммов/кубов
- Часто в туториалах описывают неправильный/неполный алгоритм, выдающий false positive пересечения – не страшно для frustum culling, но неэффективно
- en.wikipedia.org/wiki/Hyperplane_separation_theorem
- Статья с разбором SAT и выводом алгоритмов для 2D и 3D
- Большая статья с разбором разных вариантов bounding volume

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра
  - Нужно запомнить матрицу проекции предыдущего кадра

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра
  - Нужно запомнить матрицу проекции предыдущего кадра
  - Может давать неточный результат

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра
  - Нужно запомнить матрицу проекции предыдущего кадра
  - Может давать неточный результат
- Лучше построить max-mipmaps по буферу глубины (HiZ – hierarchical Z): специальным шейдером строить mipmaps, вычисляя максимум среди группы 2x2 пикселей

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра
  - Нужно запомнить матрицу проекции предыдущего кадра
  - Может давать неточный результат
- Лучше построить max-mipmaps по буферу глубины (HiZ – hierarchical Z): специальным шейдером строить mipmaps, вычисляя максимум среди группы 2x2 пикселей
  - По размеру объекта (ocludee) вычисляем mipmap-уровень: если в Z-буфере значение меньше, чем минимальная глубина нашего объекта, то объект не будет видно

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра
  - Нужно запомнить матрицу проекции предыдущего кадра
  - Может давать неточный результат
- Лучше построить max-mipmaps по буферу глубины (HiZ – hierarchical Z): специальным шейдером строить mipmaps, вычисляя максимум среди группы 2x2 пикселей
  - По размеру объекта (ocludee) вычисляем mipmap-уровень: если в Z-буфере значение меньше, чем минимальная глубина нашего объекта, то объект не будет видно
- Можно сгенерировать HiZ по списку известных occluders

Occlusion culling

- Не будем рисовать объекты (ocludees), закрытые другими объектами (occluders)
- **Очень** много вариаций
- Если есть заранее известные occluders (здания, ландшафт)
  - Можно растеризовать их на CPU в буфер глубины низкого разрешения, и использовать его для проверки видимости
  - Можно нарисовать их обычным способом, и затем полагаться на early depth test (z pre-pass)
- Можно использовать буфер глубины с предыдущего кадра
  - Нужно запомнить матрицу проекции предыдущего кадра
  - Может давать неточный результат
- Лучше построить max-mipmaps по буферу глубины (HiZ – hierarchical Z): специальным шейдером строить mipmaps, вычисляя максимум среди группы 2x2 пикселей
  - По размеру объекта (ocludee) вычисляем mipmap-уровень: если в Z-буфере значение меньше, чем минимальная глубина нашего объекта, то объект не будет видно
- Можно сгенерировать HiZ по списку известных occluders
- Можно запомнить список видимых объектов с прошлого кадра и использовать их как occluders

Occlusion culling

- Главное – избежать *pipeline stall*, т.е. блокирующего ожидания окончания работы GPU на CPU

Occlusion culling

- Главное – избежать *pipeline stall*, т.е. блокирующего ожидания окончания работы GPU на CPU
- Если Z-буфер для occlusion culling (возможно, в виде HiZ) построен на CPU, проверку тоже можно осуществлять на CPU

Occlusion culling

- Главное – избежать *pipeline stall*, т.е. блокирующего ожидания окончания работы GPU на CPU
- Если Z-буфер для occlusion culling (возможно, в виде HiZ) построен на CPU, проверку тоже можно осуществлять на CPU
- Если Z-буфер построен на GPU (взят с прошлого кадра, или построен по известным occluders), проверку хочется делать на GPU

Occlusion culling

- Главное – избежать *pipeline stall*, т.е. блокирующего ожидания окончания работы GPU на CPU
- Если Z-буфер для occlusion culling (возможно, в виде HiZ) построен на CPU, проверку тоже можно осуществлять на CPU
- Если Z-буфер построен на GPU (взят с прошлого кадра, или построен по известным occluders), проверку хочется делать на GPU
  - Можно использовать compute shaders + indirect rendering (OpenGL 4.0)

Occlusion culling

- Главное – избежать *pipeline stall*, т.е. блокирующего ожидания окончания работы GPU на CPU
- Если Z-буфер для occlusion culling (возможно, в виде HiZ) построен на CPU, проверку тоже можно осуществлять на CPU
- Если Z-буфер построен на GPU (взят с прошлого кадра, или построен по известным occluders), проверку хочется делать на GPU
  - Можно использовать compute shaders + indirect rendering (OpenGL 4.0)
  - Можно использовать occlusion queries + conditional rendering

Occlusion culling: conditional rendering

- Выключаем рисование в z-буфер и в цветовой буфер (нас интересует только то, **будет ли нарисован** объект)

Occlusion culling: conditional rendering

- Выключаем рисование в z-буфер и в цветовой буфер (нас интересует только то, **будет ли нарисован** объект)
- Внутри `glBeginQuery(GL_ANY_SAMPLES_PASSED, query_id)` рисуем дешёвую аппроксимацию объекта (напр. bounding box)

Occlusion culling: conditional rendering

- Выключаем рисование в z-буфер и в цветовой буфер (нас интересует только то, **будет ли нарисован** объект)
- Внутри `glBeginQuery(GL_ANY_SAMPLES_PASSED, query_id)` рисуем дешёвую аппроксимацию объекта (напр. bounding box)
- Обратно включаем рисование в z-буфер и в цветовой буфер

Occlusion culling: conditional rendering

- Выключаем рисование в z-буфер и в цветовой буфер (нас интересует только то, **будет ли нарисован** объект)
- Внутри `glBeginQuery(GL_ANY_SAMPLES_PASSED, query_id)` рисуем дешёвую аппроксимацию объекта (напр. bounding box)
- Обратно включаем рисование в z-буфер и в цветовой буфер
- Внутри пары `glBeginConditionalRender(query_id, GL_QUERY_NO_WAIT)` и `glEndConditionalRender` рисуем сам объект

Occlusion culling: ссылки

- Статья про conditional rendering на OpenGL wiki
- Статья про много вариантов реализации occlusion culling
- Ещё одна статья
- И ещё одна статья
- И ещё одна, очень большая, статья